LAB 1: *THU THẬP DỮ LIỆU WEB*

(***)

❖ MÔ TẢ BÀI LAB:

I – LÝ THUYẾT

Hiện nay hầu hết các doanh nghiệp, tổ chức kinh doanh đều có nhiều hoạt động mạnh mẽ trên các nền tảng website và điều đó dẫn tới việc một khối lượng rất lớn dữ liệu được liên tục tạo ra trên nền tảng website. Để phục vụ việc học tập nghiên cứu cũng như phân tích dữ liệu cho quá trình đưa ra các quyết định kinh doanh, ta có thể lấy dữ liệu từ web bằng python là cách tiện dụng và nhanh nhất.

I – THỰC HÀNH.

1. Cài đặt thư viện

Để lấy dữ liệu từ web bằng python, đầu tiên chúng ta cần cài đặt **Requests**:

pip install requests (hoặc python –m pip install requests)

Cài đặt Pilow:

pip install Pillow (hoặc python –m pip install Pillow)

2. Crawl dữ liệu từ danh sách tin tức mới nhất lấy dữ liệu

- Để lấy dữ liệu từ web bằng python, đầu tiên chúng ta cần cài đặt **Requests**:

- Hiểu một cách đơn giản thì ***Module Request*** dùng để gửi ***HTTP request***, điều này cũng giống như thao tác ta thường làm khi tìm kiếm thứ gì đó trên mạng: Vào trình duyệt, gõ vào thanh tìm kiếm "mcivietnam" và enter, ta sẽ nhận được giao diện của trang web MCI hoặc một dạng dữ liệu khác trả về. Để lấy được dữ liệu trả về chúng ta phải sử dụng một module để hỗ trợ và Request sẽ giúp ta thực hiện việc đó.

```
import requests

from bs4 import BeautifulSoup

response = requests.get("https://vnexpress.net/bong-da")

print(response)
```

```
<Response [200]>
```

- Kết quả trả về như thế này:

<Response [200]>

- Đây không phải là dữ liệu mà chúng ta cần, vì vậy, phải thêm một vài thuộc tính nữa để lấy dữ liệu từ web như mong muốn của chúng ta:

```
import requests

from bs4 import BeautifulSoup

response = requests.get("https://vnexpress.net/bong-da")

print(response.content)
```

```
b'<!DOCTYPE html>\n<html lang="vi" xmlns="http://www.w3.org/1999/xhtml">\n<head>\n<title>B\xc3\x93NG
```


```
b'<!DOCTYPE html>\n<html lang="vi" xmlns="http://www.w3.org/1999/xhtml">\n<head>\n<title>B\xc3\x93NG \xc4\x90\xc3\x
\xe1\xbb\xb1c ti\xe1\xba\xbfp b\xc3\xb3ng \xc4\x91\xc3\xa1, bongda24h, bongdaso, k\xe1\xba\xbft qu\xe1\xba\xa3 b\xc
ontent="2"/>\n<!-- add meta for pvtt3334 -->\n<!-- end meta for pvtt -->\n<!-- META FOR FACEBOOK -->\n<meta propert
b1c tuy\xe1\xba\xbfn, b\xe1\xba\xa3ng x\xe1\xba\xbfp h\xe1\xba\xa1ng, l\xe1\xbb\x8bch thi \xc4\x91\xe1\xba\xa5u, k\
ress.net/bong-da"/>\n<meta name="twitter:title" content="B\xc3\x93NG \xc4\x90\xc3\x81: Tin t\xe1\xbb\xa9c, k\xe1\xb
ess.net/bong-da" hreflang="vi-vn"/>\n<link rel="dns-prefetch" href="https://scdn.vnecdn.net"/>\n<link rel="dns-pref
s/restruct/i/v738/logos/72x72.png" sizes="72x72">\n<link rel="apple-touch-icon-precomposed" href="https://s1cdn.vne
":"http://schema.org",\n                                    "@type":"WebSite",\n                                    "name":
:[\n                                \n          {\n              "@type":"ListItem",\n               "posi
nst o=JSON.parse(e.data),l=[];for(const e in o)for(const s in o[e])if(void 0!==o[e][s].api_url&&!1===l.includes(o[e
?window.location.hash:window.location.search).replace(/^[#,?]+/g,\'\').split(\'&\');if(_itmSource){window.itmSource
if(window.itmSource.vn_aid){dataLayer.push({\'vn_aid\':window.itmSource.vn_aid});}if(window.itmSource.vn_test){data
/vn_source=/.test(this.href)){data_itm_source=\'\';if(meta_ttaid){data_itm_source=\'&vn_aid=\'+meta_ttaid.getAttrib
(href==window.location.href||href==window.location.href+\'#\'){window.dataLayer=window.dataLayer||[];if(type==\'log
:{"name":"Ngo\\u1ea1i h\\u1ea1ng Anh","logo":"https:\\/\\/s1.vnecdn.net\\/vnexpress\\/restruct\\/i\\/v391\\/v2_2019
":"\\/the-thao\\/du-lieu-bong-da\\/giai-dau\\/seriea","logo_bangdiem":"https:\\/\\/s.vnecdn.net\\/thethao\\/restruc
\\/v2_2019\\/pc\\/graphics\\/logo_bundesliga.png","link":"\\/the-thao\\/du-lieu-bong-da\\/giai-dau\\/bundesliga","l
re_in_box":true,"tt_category_id":1004825},"403":{"name":"Euro 2021","logo":"https:\\/\\/s1.vnecdn.net\\/vnexpress\\
et\\/vnexpress\\/restruct\\/i\\/v391\\/v2_2019\\/pc\\/graphics\\/logo_coparey.png","link":"\\/the-thao\\/du-lieu-bo
ions League","logo":"https:\\/\\/s1.vnecdn.net\\/vnexpress\\/restruct\\/i\\/v391\\/v2_2019\\/pc\\/graphics\\/logo_n
t.toUTCString()+";domain=vnexpress.net;path=/";window.dataLayer=window.dataLayer||[];dataLayer.push({"pageCategory"
taLayer","GTM-N3FNJF");var _siteId="11";</script>\n<style>.lazier{width:1px;height:1px}#_havien1_2.lazier,#_havien2
rage.setItem(\'check_storage\',\'local storage\');window.supportLS=true;}catch(e){console.log(e);window.supportLS=f
```

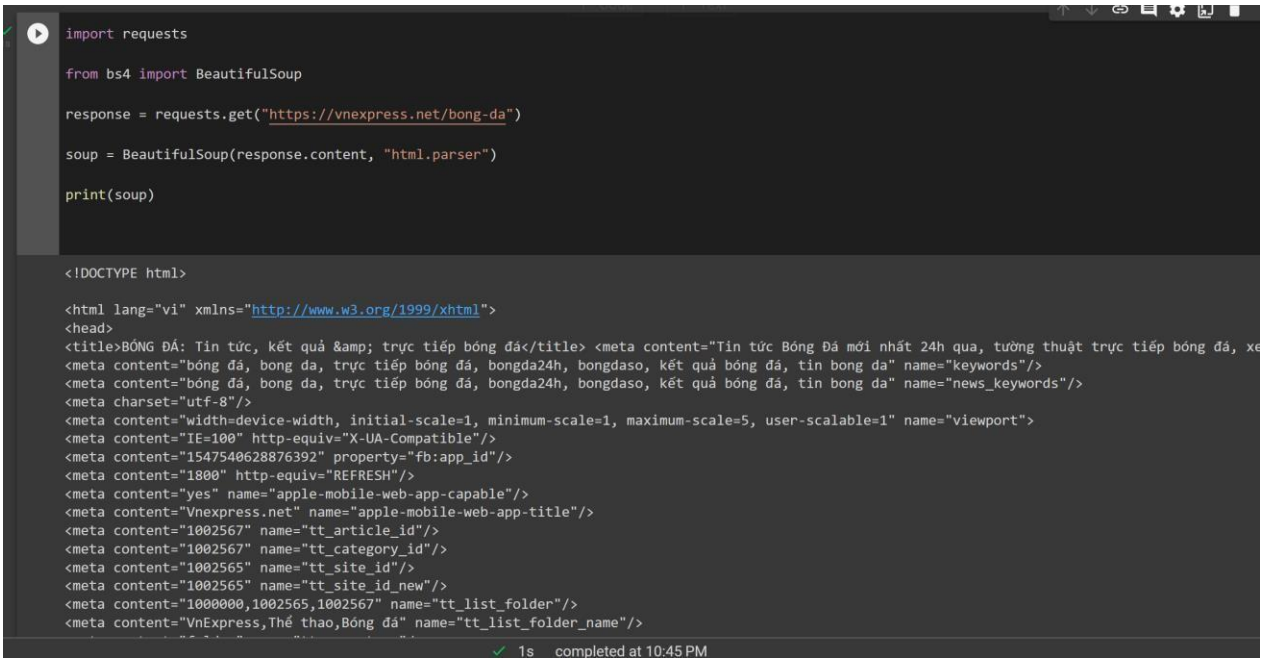
3. Tách dữ liệu crawl được từ web

- Sau khi đã lấy được dữ liệu, việc tiếp theo cần làm là phải tách các dữ liệu ra thành dạng cây để thuận tiện hơn cho quá trình truy xuất dữ liệu. Các phổ biến là dùng module **BeautifulSoup4**. Cú pháp cài đặt module:

pip install beautifulsoup4 (hoặc python –m pip install beautifulsoup4

- Tham khao link để biết thêm cách vận dụng trong **BeautifulSoup**

(https://www.crummy.com/software/BeautifulSoup/bs4/doc/)



4. Phân tích dữ liệu

- Sau khi đã hoàn thành, bước tiếp theo ta cần làm là phân tích xem dữ liệu đang cần có thể lấy được ở đâu. Ví dụ ta cần lấy chi tiết về một bài viết cụ thể, ta cần biết liên kết để truy cập đến bài viết đó. Ta có thể tìm kiếm thông tin đó bằng cách ấn **F12** và tìm xem link bài báo ở đâu. Ví dụ chúng ta tìm thấy link bài báo ở trong thẻ <a>, nằm trong thẻ **h2** và có class là **"title-news"**. Vậy chúng ra cần phải lọc tất cả thẻ **h2** có class "titlenews" và lấy thẻ **a** trong đó, đoạn mã cần thiết được xây dựng là:

```
import requests

from bs4 import BeautifulSoup

response = requests.get("https://vnexpress.net/bong-da")

soup = BeautifulSoup(response.content, "html.parser")

titles = soup.findAll('h2', class_='title-news')

links = [link.find('a').attrs["href"] for link in titles]

print(links)
```

```
['https://vnexpress.net/barca-bi-to-chuyen-1-5-trieu-usd-cho-trong-tai-4571080.html', 'https://vnexpress.net/xem-
```

4. Lấy dữ liệu chi tiết của từng bài

```
import requests

from bs4 import BeautifulSoup

response = requests.get("https://vnexpress.net/bong-da")

soup = BeautifulSoup(response.content, "html.parser")

titles = soup.findAll('h2', class_='title-news')

links = [link.find('a').attrs["href"] for link in titles]

#print(links)

for link in links:

    news = requests.get(link)

    soup = BeautifulSoup(news.content, "html.parser")

    title = soup.find("h1", class_="title-detail").text

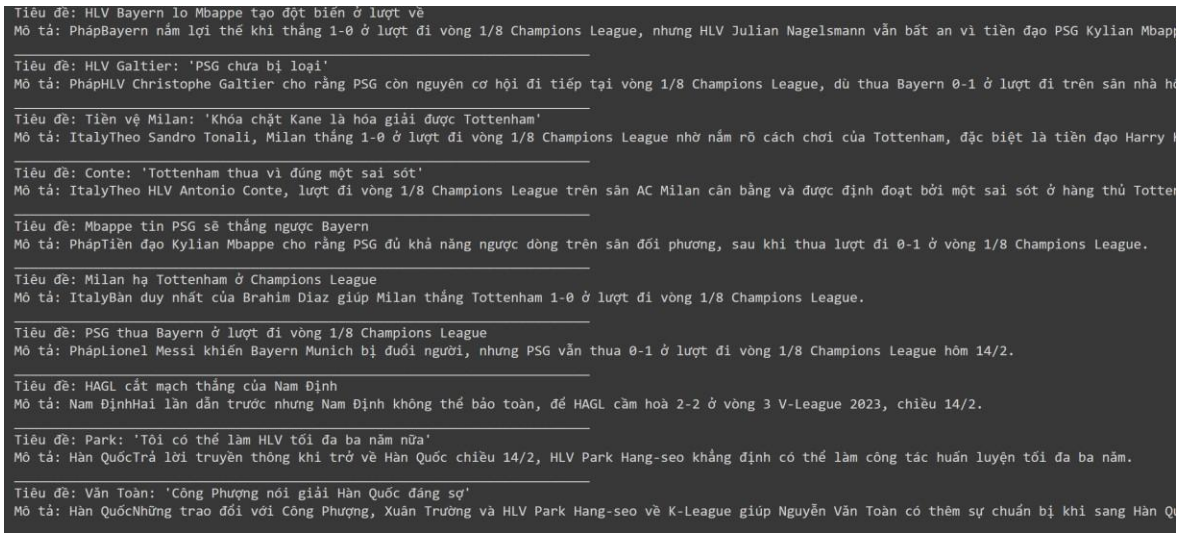
    abstract = soup.find("p", class_="description").text

    print("Tiêu đề: " + title)

    print("Mô tả: " + abstract)


    print("_____")
```

Kết quả:



5. Vận dụng kiến thức để lưu nội dung thành file *.csv

6. Thực hành với các trang khác lấy dữ liệu để giúp việc thu tập dữ liệu nhanh.

========== HẾT ==========