LAB 2: *LÀM VIỆC VỚI DỮ LIỆU BỊ THIẾU TRONG THƯ VIỆN PANDAS*

(***)

❖ MÔ TẢ BÀI LAB:

I – LÝ THUYẾT.

Missing data là gì?

Missing data là dữ liệu bị thiếu, được hiển thị như NaN, Nat, Null, N/A, v.v. Missing data xuất hiện do nhiều nguyên nhân như:

- *Người dùng quên điền.*
- *Dữ liệu bị mất trong quá trình chuyển thủ công từ cơ sở dữ liệu cũ.*
- *Lỗi của chương trình.*
- *Thiếu dữ liệu do trùng hợp v.v.*

Missing data có thể được phân thành 3 loại: Missing at Random (dữ liệu khuyết ngẫu nhiên), Missing Completely at Random (dữ liệu thiếu hoàn toàn ngẫu nhiên) và Missing Not at Random (dữ liệu khuyết không ngẫu nhiên).

Thư viên Pandas xem **None** và **NaN** về cơ bản có thể hoán đổi cho nhau để chỉ ra các giá trị bị thiếu hoặc không. Để tạo thuận lợi cho quy ước này, có một số chức năng hữu ích để phát hiện, loại bỏ và thay thế các giá trị null trong Pandas DataFrame:

II – THỰC HÀNH.

1. Thực hiện đoạn code trong Python để phát hiện những phần dữ liệu bị thiếu.

```python
# importing pandas as pd
import pandas as pd

# importing numpy as np
import numpy as np

# tạo dictionary of lists
dict = {'Điểm dòng 1':[100, 90, np.nan, 95],
        'Điểm dòng 2': [30, 45, 56, np.nan],
        'Điểm doàn 3':[np.nan, 40, 80, 98]}

# Tạo một dataframe từ list
df = pd.DataFrame(dict)

# Dùng hàm isnull()

print(df.isnull())
```

Kết quả:

	Điểm dòng 1	Điểm dòng 2	Điểm doàn 3
0	False	False	True
1	False	False	False
2	True	False	False
3	False	True	False

2. Thực hiện đoạn code trong Python làm việc với tập hợp dataset cho trước.

```python
import pandas as pd
....
# Làm việc với file csv file
data = pd.read_csv("employees.csv")
....
# Tạo bool series trả về True có giá trị NaN
bool_series = pd.isnull(data["Gender"])
....
# Lọc dữ liệu
# Hiển thi dữ liệu dòng Gender = NaN

print(data[bool_series])
```

Kết quả:

```
    First Name Gender  ... Senior Management                 Team
20         Lois    NaN  ...              True                Legal
22       Joshua    NaN  ...              True       Client Services
27        Scott    NaN  ...             False                Legal
31        Joyce    NaN  ...             False              Product
41    Christine    NaN  ...              True  Business Development
..          ...    ...  ...               ...                  ...
961     Antonio    NaN  ...             False                Legal
972      Victor    NaN  ...              True                Sales
985     Stephen    NaN  ...             False                Legal
989      Justin    NaN  ...             False                Legal
995       Henry    NaN  ...             False         Distribution

[145 rows x 8 columns]
```

3. Điền các giá trị còn thiếu bằng cách sử dụng fillna(), replace() và interpolate()

- **Với hàm fillna()**

```
# importing pandas as pd
import pandas as pd

# importing numpy as np
import numpy as np

# dictionary of lists
dict = {'Điểm dòng 1':[100, 90, np.nan, 95],
        'Điểm dòng 2':[30, 45, 56, np.nan],
        'Điểm dòng 3':[np.nan, 40, 80, 98]}

# Tạo một dataframe từ dictionary
df = pd.DataFrame(dict)

# Tìm những giá trị còn thiếu với fillna()
print(df.fillna(0))
```

Kết quả

```
   Điểm dòng 1  Điểm dòng 2  Điểm dòng 3
0        100.0         30.0          0.0
1         90.0         45.0         40.0
2          0.0         56.0         80.0
3         95.0          0.0         98.0
```

- **Với hàm fillna()**

```
# importing pandas as pd
import pandas as pd

# importing numpy as np
import numpy as np

# dictionary of lists
dict = {'Điểm dòng 1':[100, 90, np.nan, 95],
        'Điểm dòng 2': [30, 45, 56, np.nan],
        'Điểm dòng 3':[np.nan, 40, 80, 98]}

# Tạo một dataframe từ dictionary
df = pd.DataFrame(dict)

# điền một giá trị còn thiếu với những giá trị trước đó
print(df.fillna(method ='pad'))
```

Kết quả

	Điểm dòng 1	Điểm dòng 2	Điểm dòng 3
0	100.0	30.0	NaN
1	90.0	45.0	40.0
2	90.0	56.0	80.0
3	95.0	56.0	98.0

- **Với hàm replace ()**

```
# importing pandas package
import pandas as pd
import numpy as np


data = pd.read_csv("employees.csv")

#Thay thế NaN trong dataframe với giá trị -99
data_new = data.replace(to_replace = np.nan, value = -88)
print(data_new)
```

Kết quả:

```
    First Name  Gender  ... Senior Management                 Team
0       Douglas    Male  ...              True            Marketing
1        Thomas    Male  ...              True                  -88
2         Maria  Female  ...             False              Finance
3         Jerry    Male  ...              True              Finance
4         Larry    Male  ...              True      Client Services
..          ...     ...  ...               ...                  ...
995       Henry     -88  ...             False         Distribution
996     Phillip    Male  ...             False              Finance
997     Russell    Male  ...             False              Product
998       Larry    Male  ...             False  Business Development
999      Albert    Male  ...              True                Sales

[1000 rows x 8 columns]
```

- **Sử dụng hàm interpolate() để điền các giá trị còn thiếu bằng phương pháp tuyến tính**

```
import pandas as pd

df = pd.DataFrame({"A":[12, 4, 5, None, 1],
                   "B":[None, 2, 54, 3, None],
                   "C":[20, 16, None, 3, 8],
                   "D":[14, 3, None, None, 6]})

print(df)

print("================================")
data_new= df.interpolate(method ='linear', limit_direction ='forward')

print(data_new)
```

Kết quả

```
      A     B     C     D
0  12.0   NaN  20.0  14.0
1   4.0   2.0  16.0   3.0
2   5.0  54.0   NaN   NaN
3   NaN   3.0   3.0   NaN
4   1.0   NaN   8.0   6.0
================================
      A     B     C     D
0  12.0   NaN  20.0  14.0
1   4.0   2.0  16.0   3.0
2   5.0  54.0   9.5   4.0
3   3.0   3.0   3.0   5.0
4   1.0   3.0   8.0   6.0
```

==========HẾT==========