LAB 3: *LÀM SẠCH DỮ LIỆU*

(***)

❖ MÔ TẢ BÀI LAB:

I – LÝ THUYẾT

Làm sạch dữ liệu là một bước cực kỳ quan trọng trong bất kỳ dự án máy học nào.

Trong dữ liệu lập bảng, có nhiều kỹ thuật phân tích thống kê và trực quan hóa dữ liệu khác nhau mà chúng có thể sử dụng để khám phá dữ liệu của mình nhằm xác định các quá trình làm sạch dữ liệu mà chúng ta có thể muốn thực hiện.

Hiện nay có một số thao tác làm sạch dữ liệu rất cơ bản nên thực hiện trên các mô hình máy học. Những điều này cơ bản chúng ta cần thực, điều này thường bị bỏ qua bởi những người dày dạn kinh nghiệm, nếu bỏ qua các bước này, các mô hình có thể bị hỏng hoặc báo cáo kết quả hoạt động có thể bị sai lệch.

Chúng ta cùng tìm hiểu cách thức làm sạch dữ liệu với các mục sau đây:

+ Cách tra cột trong dữ liệu

+ Cách đổi tên cột trong dữ liệu

+ Cách đặt dấu gạch dưới ở tất cả các cột

+ Cách thay thế ký tự hoặc khoảng trống trong tên cột

+ Cách viết hoa/viết thường các cột

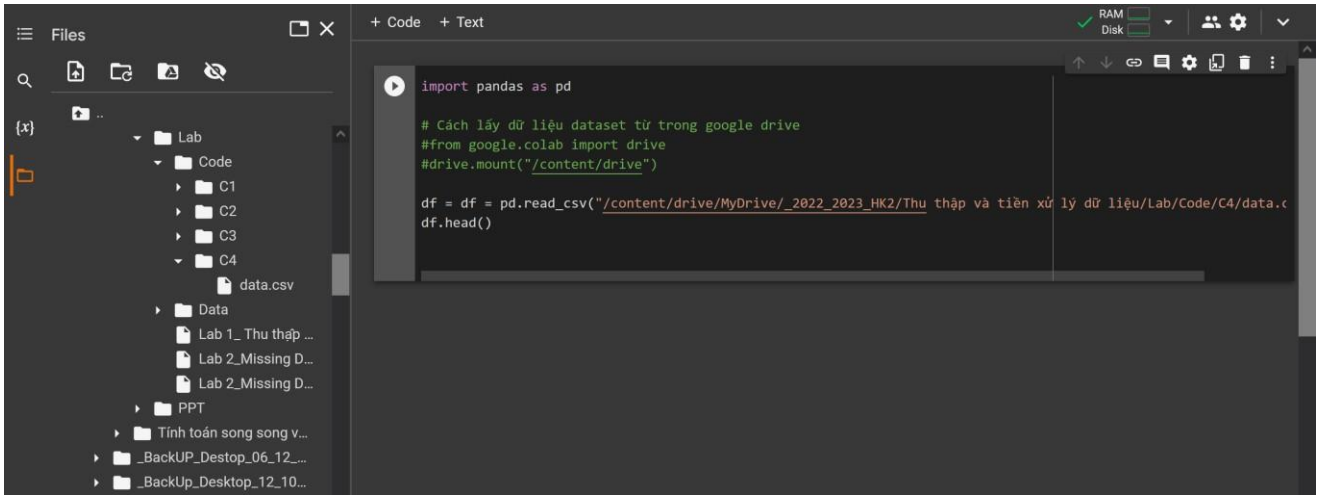
+ Cách chọn tất cả các cột trừ một cột

+ Cách chọn cột theo thứ tự hoặc cụm từ cụ thể (df.filter)

+ Cách chọn nhóm tên cột

I – THỰC HÀNH. (Thực hiện trên https://colab.research.google.com)

1. Cách lấy dữ liệu dataset từ google driver.



	First Name	Last name	Age	SALARY	STREET Address1	STREET Address2	STREET Address3	email
0	Joel	Padilla	10/28/2019	$92.32	431-6530 Eu, Rd.	364-2264 Augue Rd.	P.O. Box 864, 3882 Orci Street	eu@nibh.com
1	Fritz	Tyler	09/27/2019	$83.91	Ap #377-2267 Ac Av.	979-2228 Vel Ave	9865 Eu Av.	est.ac.mattis@malesuadafringilla.net
2	Wing	Phelps	02/18/2019	$17.15	Ap #545-5786 Pulvinar Ave	Ap #973-5781 Sagittis Avenue	9959 Ut St.	dolor@cubilia.net
3	Ryan	Ross	05/21/2019	$45.97	634-7858 Id Road	907-8824 Fringilla Ave	318-5271 In Ave	interdum.libero.dui@vitaeerat.com
4	Drake	Day	01/09/2020	$84.38	999-8221 Tempor, St.	297-6939 Turpis. Ave	P.O. Box 638, 6932 Laoreet Rd.	nulla.Integer.vulputate@liberoat.ca

2. Thực hiện các thao tác trên dòng dữ liệu

```
[40] #Thay đổi tiêu đề các dòng thành chữ thường
     df.columns.str.lower()

     Index(['first name', 'last name', 'age', 'salary', 'street address1',
            'street address2', 'street address3', 'email'],
           dtype='object')

[41] ### Thay đổi thành chữ in hoa
     df.columns.str.upper()

     Index(['FIRST NAME', 'LAST NAME', 'AGE', 'SALARY', 'STREET ADDRESS1',
            'STREET ADDRESS2', 'STREET ADDRESS3', 'EMAIL'],
           dtype='object')

     ### Ký tự đầu in hoa
     df.columns.str.title()

     Index(['First Name', 'Last Name', 'Age', 'Salary', 'Street Address1',
            'Street Address2', 'Street Address3', 'Email'],
           dtype='object')
```

```
### Thay thế khoảng trắng bằng dấu _
df.columns.str.replace(' ','_')

Index(['First_Name', 'Last_name', 'Age', 'SALARY', 'STREET_Address1',
       'STREET_Address2', 'STREET_Address3', 'email'],
      dtype='object')

### Thay đổi tên dòng Age thành Date of Birth
df.rename(columns={'Age':'Date of Birth'})
```

	First Name	Last name	Date of Birth	SALARY	STREET Address1	STREET Address2	STREET Address3	email
0	Joel	Padilla	10/28/2019	$92.32	431-6530 Eu, Rd.	364-2264 Augue Rd.	P.O. Box 864, 3882 Orci Street	eu@nibh.com
1	Fritz	Tyler	09/27/2019	$83.91	Ap #377-2267 Ac Av.	979-2228 Vel Ave	9865 Eu Av.	est.ac.mattis@malesuadafringilla.net
2	Wing	Phelps	02/18/2019	$17.15	Ap #545-5786 Pulvinar Ave	Ap #973-5781 Sagittis Avenue	9959 Ut St.	dolor@cubilia.net
3	Ryan	Ross	05/21/2019	$45.97	634-7858 Id Road	907-8824 Fringilla Ave	318-5271 In Ave	interdum.libero.dui@vitaeerat.com
4	Drake	Day	01/09/2020	$84.38	999-8221 Tempor, St.	297-6939 Turpis. Ave	P.O. Box 638, 6932 Laoreet Rd.	nulla.Integer.vulputate@liberoat.ca

```
[51] df.columns.values[7] = 'Email Address'
     df.columns
```

```
Index(['First Name', 'Last name', 'Date of Birth', 'SALARY', 'STREET Address1',
       'STREET Address2', 'STREET Address3', 'Email Address'],
      dtype='object')
```

```
[52] ### Cho tất cả trừ điều kiện
     df.columns[df.columns != 'SALARY']
```

```
### Cho tất cả trừ điều kiện dùng phủ định isin
df.loc[:,~df.columns.isin(['SALARY'])].columns
```

```
Index(['First Name', 'Last name', 'Date of Birth', 'STREET Address1',
       'STREET Address2', 'STREET Address3', 'Email Address'],
      dtype='object')
```

```
[54] ### Chọn tên cột bắt đầu bằng ký tự trong điều kiên
     df.filter(like='STREET').columns
```

```
Index(['STREET Address1', 'STREET Address2', 'STREET Address3'], dtype='object')
```

```
[57] ### Chọn tên cột với các ký tự cuối trong điều kiện
     df.loc[:,df.columns.str.endswith('ame')].columns
```

```
Index(['First Name', 'Last name'], dtype='object')
```

```
[58] ###  Hiện tên cột với các ký tự cuối trong điều kiện với bộ lọc và giá trị biến truyền
     df.filter(regex='ame$',axis=1).columns
```

```
Index(['First Name', 'Last name'], dtype='object')
```

```
[60] ### Hiện một nhóm tên cột
     df.columns.values[0:4]
```

```
array(['First Name', 'Last name', 'Date of Birth', 'SALARY'], dtype=object)
```

III – BÀI TẬP

1. Sử dụng dữ liệu Dataset tại:

https://drive.google.com/file/d/1YeqC-CBZi4wIHJdWP3Cg6AGSXJlfBZpd/view?usp=sharing

2. Viết code thực hiện những công việc sau:

2.1. Đọc tệp csv vào ***Dataframe***

2.2. Tìm trong Dataframe những dữ liệu bị thiếu 2.3. Xem cột

NUM_BEDROOM *và tìm những giá trị* ***NaN***

2.4. Tổng giá trị còn thiếu trong ***Dataframe****.*

2.5. Điền giá trị 126 vào ô bị thiếu trong cột "ST_NUM"

2.5. Tay thế missing values trong cột ***"NUM_BEDROOMS"*** *bằng giá trị trung vị (median).*

==========